

# Detecção Robusta de Javali (*Sus scrofa*) e Javaporco em Lavouras Brasileiras via Visão Computacional

Ítalo Manzine A. D. Garofalo<sup>1</sup>, Murillo Pagani Martins<sup>1</sup>  
Orientador: Alison Roberto Panisson<sup>1</sup>

<sup>1</sup>Departamento de Computação – Universidade Federal de Santa Catarina (UFSC)  
Araranguá – SC – Brasil

{italo.manzine, murillo.pagani.martins}@grad.ufsc.br, alison.panisson@ufsc.br

**Abstract.** *We present the preliminary design of a computer-vision system to detect invasive wild boar (*Sus scrofa*) and hybrids (“javaporco”) in Brazilian croplands with high accuracy, minimizing false positives on non-target wildlife and humans. We compare one-stage (YOLO) and transformer-based (DETR) detectors, discuss training data from public camera-trap and citizen-science sources, and propose evaluation beyond mAP, emphasizing safety-critical precision and low false alarms. The system is designed to integrate with legally-authorized control workflows.*

**Resumo.** *Apresentamos o desenho preliminar de um sistema de visão computacional para detectar javali (*Sus scrofa*) e híbridos (“javaporco”) em lavouras brasileiras com alta acurácia, reduzindo falsos positivos em fauna não alvo e humanos. Comparamos detectores de uma etapa (YOLO) e baseados em transformers (DETR), descrevemos dados de treino de acervos públicos (camera-traps e ciência cidadã) e propomos avaliação além de mAP, priorizando precisão e baixo alarme falso em cenários de segurança. O sistema integra-se a fluxos de controle autorizados em conformidade com a legislação.*

## 1. Introdução

O javali (*Sus scrofa*) e seus híbridos com suíno doméstico (“javaporco”) são espécie exótica invasora no Brasil, com impactos ambientais e econômicos relevantes, incluindo danos em lavouras e riscos sanitários [Kmetiuk et al. 2023, Pedrosa et al. 2015]. O controle é regulamentado pelo Ibama (IN nº 03/2013 e atualizações) [Ibama 2013, Ibama 2019, Ibama 2022], exigindo procedimentos, registros e relatórios. Sistemas de detecção automática por visão computacional em câmeras de campo podem agilizar respostas e reduzir custos operacionais, desde que minimizem erros que possam expor espécies nativas ou pessoas a riscos. Este trabalho descreve a definição do projeto desta disciplina, propondo uma solução para o problema descrito, cobrindo a criação do trabalho relacionado e as decisões técnicas utilizadas em seu desenvolvimento (ver Figuras 3 e 4).

## 2. Trabalhos Relacionados

Há literatura consolidada sobre impactos e manejo de *Sus scrofa* no Brasil [Kmetiuk et al. 2023, Pedrosa et al. 2015, Ibama 2013, Ibama 2019, Ibama 2022,

Ibama 2020]. Em visão computacional, há estudos recentes de detecção/contagem em *camera traps* [Schütz et al. 2024] e propostas de aprimoramento de detectores para fauna (p.ex., variantes YOLO) [Chen et al. 2024]. Quanto a dados, há acervos amplos e públicos com classes relacionadas a javali/suídeos: LILA [BC 2024, BC 2021, Datasets 2024], NACTI [BC 2018] e iNaturalist (observações licenciadas) [iNaturalist 2024b, iNaturalist 2024a], além de coleções curadas menores para prototipagem [Universe 2024b, Universe 2024a]. Esses repositórios subsidiam diversidade ambiental (dia/noite, clima, distâncias) essencial para a robustez do modelo.


### **3. Fundamentação Teórica**

Esta seção apresenta os conceitos e bases que sustentam o desenvolvimento deste trabalho. São abordados aspectos biológicos e ambientais da espécie invasora, princípios de visão computacional aplicados à detecção de fauna, e os fundamentos das arquiteturas de redes neurais utilizadas na atualidade. Por fim, discutem-se questões éticas e legais envolvidas no uso de tecnologias de monitoramento ambiental.

#### **3.1. Espécie Invasora e Impactos no Brasil**

O javali é considerado uma das 100 piores espécies invasoras do mundo, e no Brasil tornou-se uma ameaça crescente à biodiversidade e à agricultura. Introduzidos inicialmente para caça e consumo, os javalis e seus híbridos com porcos domésticos, conhecidos como javaporcos, espalharam-se por diversos biomas brasileiros, especialmente no Sul e Sudeste, onde encontram abundância de alimento e ausência de predadores naturais [MINAS 2025].

Esses animais provocam uma ampla gama de impactos: destroem lavouras, competem com espécies nativas, alteram o solo e transmitem doenças como a febre aftosa e a leptospirose. O Ibama reconhece o javali como uma espécie exótica invasora, permitindo seu controle populacional por meio de manejo autorizado [do Meio Ambiente e dos Recursos Naturais Renováveis 2013]. Estudos indicam que, sem medidas eficazes, a população tende a se expandir exponencialmente, atingindo áreas de preservação e comprometendo ecossistemas inteiros [da Rosa et al. 2018].

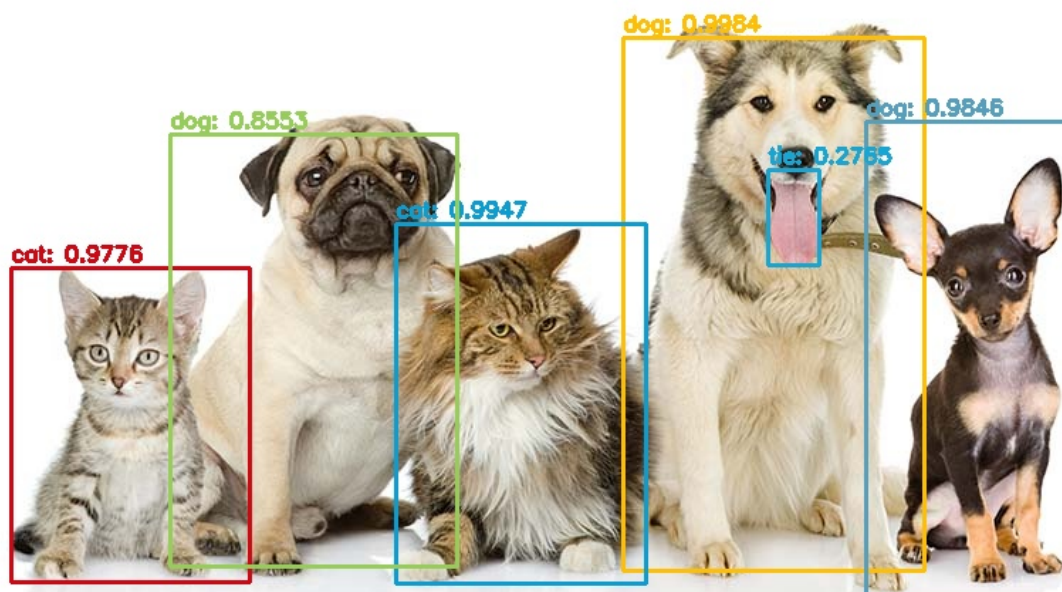


**Figure 1.** Número de municípios brasileiros com presença confirmada de populações selvagens de javali (*Sus scrofa*) entre 1965 e 2016. Fonte: BRASIL. Ministério do Meio Ambiente. \*Relatório Técnico de Gestão do Manejo de Javalis no Brasil (2013–2016)\*. Brasília: MMA, 2017. Disponível em: <https://www.gov.br/mma/>. Acesso em: 1 nov. 2025.

A identificação e o controle dessa população tornam-se, portanto, desafios urgentes. Para enfrentá-los, novas tecnologias podem ser aliadas valiosas, especialmente ferramentas capazes de detectar e monitorar animais em campo de forma automatizada.

### 3.2. Visão Computacional Aplicada à Detecção de Fauna

A visão computacional é uma área da inteligência artificial que busca permitir que máquinas interpretem o conteúdo visual do mundo. Ela tem sido amplamente aplicada em tarefas ambientais, como a contagem automática de animais, identificação de espécies e detecção de invasores em tempo real [Campbell et al. 2023].



**Figure 2. Exemplo de detecção de objetos utilizando modelo de visão computacional para identificação de cães e gatos. Fonte: Node-RED. \*Object Detection Example (Flow)\*. Disponível em: <https://flows.nodered.org/flow/>. Acesso em: 1 nov. 2025.**

Com o avanço de redes neurais profundas (deep learning), tornou-se possível alcançar precisão comparável à de especialistas humanos em diversas tarefas de classificação e detecção. Modelos como o YOLO (\*You Only Look Once\*) destacam-se pela rapidez e eficiência, sendo especialmente úteis para aplicações em vídeo e sistemas embarcados [Redmon et al. 2016].

A aplicação dessas técnicas à fauna selvagem exige, contudo, o uso de grandes conjuntos de imagens de campo. Bases como o LILA, NACTI e iNaturalist têm impulsionado o desenvolvimento de modelos mais robustos, ao oferecer dados variados de espécies e ambientes [de Sousa Pimenta 2025]. Ainda assim, desafios permanecem: iluminação variável, camuflagem natural e ruído ambiental dificultam a detecção precisa.

Essas limitações tornam essencial compreender as arquiteturas e estratégias de aprendizado de máquina que sustentam esses modelos.

### **3.3. Arquiteturas de Redes Neurais Relevantes**

As redes neurais convolucionais (CNNs) revolucionaram o campo da visão computacional, sendo a base de modelos como ResNet, EfficientNet e YOLO. Enquanto as primeiras camadas de uma CNN aprendem a detectar padrões simples, como bordas e texturas, as camadas mais profundas extraem características complexas, permitindo a identificação de espécies com alto grau de variação morfológica [LeCun et al. 2015].

Modelos mais recentes integram mecanismos de atenção e processamento multimodal, como os sistemas CLIP e LLaVA, capazes de relacionar imagens e descrições textuais [Agarwal et al. 2021]. Embora ainda pouco exploradas em contextos ecológicos, essas abordagens abrem caminhos promissores para monitoramento automatizado, unindo interpretação visual e semântica [Puglia 2023].

Entretanto, mesmo os modelos mais sofisticados dependem de dados consistentes e avaliação rigorosa.

### 3.4. Métricas e Avaliação de Desempenho

Para avaliar a eficácia de modelos de detecção, métricas como precisão, revocação e *mean Average Precision* (mAP) são amplamente utilizadas [Everingham et al. 2010]. Elas permitem mensurar o equilíbrio entre acertos e falsos positivos, aspecto crucial em cenários de fauna, onde erros podem gerar interpretações ambientais equivocadas.

Além disso, a calibragem de confiança dos modelos é um fator importante para sistemas de campo. Modelos bem calibrados oferecem previsões mais confiáveis, especialmente quando aplicados em contextos sensíveis, como o manejo de espécies invasoras [Nandutu et al. 2023].

A busca por métricas éticas e transparentes leva à reflexão sobre os impactos sociais e ambientais do uso dessas tecnologias.

### 3.5. Aspectos Éticos e Legais no Uso de IA Ambiental

O uso de inteligência artificial em contextos ambientais traz não apenas vantagens técnicas, mas também uma série de implicações éticas, sociais e legais que precisam ser cuidadosamente consideradas. Sistemas de monitoramento automatizado operam frequentemente em áreas sensíveis, captando informações sobre a fauna, o ambiente e, em alguns casos, sobre pessoas envolvidas no manejo. Essa coleta de dados demanda atenção especial à privacidade, ao consentimento e à segurança da informação, pilares centrais em qualquer aplicação de IA moderna [Jobin et al. 2019].

No Brasil, o controle do javali é regulamentado pelo Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis (Ibama), que define critérios específicos para o manejo e abate da espécie, qualquer sistema automatizado voltado à detecção ou monitoramento deve respeitar essas normas, garantindo que o uso da tecnologia não amplie riscos ambientais nem comprometa o bem-estar animal. Além disso, a Lei nº 9.605/1998, que trata dos crimes ambientais, estabelece sanções para o uso indevido de instrumentos que possam causar danos à fauna silvestre, reforçando a importância de que soluções tecnológicas operem dentro de limites legais claros [Brasil 1998].

Outro ponto ético relevante diz respeito à transparência algorítmica. Modelos de visão computacional podem reproduzir vieses presentes nos dados de treinamento, por exemplo, identificar incorretamente espécies nativas como invasoras ou priorizar ambientes mais fotogênicos e acessíveis. Esses erros podem gerar distorções científicas e decisões de manejo equivocadas. Assim, é fundamental documentar o processo de treinamento, as fontes de dados e as métricas utilizadas, promovendo auditabilidade e reprodutibilidade científica [Fabian et al. 2023]. Essas reflexões reforçam a necessidade de um uso ético, transparente e colaborativo da inteligência artificial aplicada à conservação ambiental.

## 4. Desenvolvimento (versão prévia)

### 4.1. Objetivo e requisitos

Detectar, em tempo quase real, javali/javaporco com alta **precisão** em cenários agrícolas. Requisitos: (i) sensibilidade a diferentes distâncias/ângulos/noite; (ii) **baixíssimo falso**

**positivo** para humanos e fauna não alvo; (iii) execução em borda (Jetson/CPU+TPU) e integração com fluxo de controle autorizado (alerta, documentação e encaminhamento).

## 4.2. Dados

Fontes: LILA Camera Traps, NACTI, iNaturalist (dados licenciados abertos) e coleções curadas menores para *bootstrapping* [BC 2024, BC 2021, Datasets 2024, BC 2018, iNaturalist 2024b, iNaturalist 2024a, Universe 2024b, Universe 2024a]. Unificação de rótulos (“wild boar”, “boar”, “feral pig”) e separação de suíno doméstico para classificador auxiliar. *Split* por local/condição para reduzir *leakage*.

## 4.3. Modelos e justificativa

Compararemos YOLOv8/YOLOv11 (eficiência em borda), DETR/Deformable-DETR (oclusões) e Faster R-CNN/RetinaNet (baselines). Rastreamento (ByteTrack/OC-SORT) para reduzir falsos positivos quadro a quadro. Para noturno, *augmentation* de baixa iluminação e uso de IR quando disponível [Schütz et al. 2024, Chen et al. 2024].

## 4.4. Métricas e protocolo

Além de mAP@.50:.95, otimizaremos Precision@0.5 para as classes alvo, *False Positive Rate* específico em “humano/fauna não alvo” e *Time-to-Alert*. Validação *leave-one-location-out* para generalização geográfica.

## 4.5. Arquitetura proposta

Captura → pré-processamento → detecção → filtro semântico (doméstico vs. selvagem; humano/fauna não alvo) → rastreamento → decisão temporal → alerta, registro auditável e encaminhamento ao fluxo de controle autorizado.

## 4.6. Aspectos legais e éticos

O sistema tem como objetivo **identificar com precisão** javali/javaporco e **acionar fluxos de controle permitidos pela legislação brasileira**, incluindo controle letal quando expressamente autorizado e conduzido por **operadores habilitados** e devidamente registrados, em conformidade com a Instrução Normativa Ibama nº 03/2013 e atualizações [Ibama 2013, Ibama 2019, Ibama 2022]. A plataforma manterá trilha de auditoria (registros de detecção, horário, localização e evidências visuais) para suporte à prestação de contas, bem como salvaguardas para evitar acionamento indevido (p.ex., bloqueio quando houver humanos identificados no quadro, limiares temporais e duplo fator de confirmação).

## 5. Ilustrações (referência visual)



Figure 3. Javali (*Sus scrofa*) em ambiente natural. Fonte: Wikimedia Commons, arquivo *Wildschwein, Nähe Pulverstampftor (cropped)* [Commons 2025].

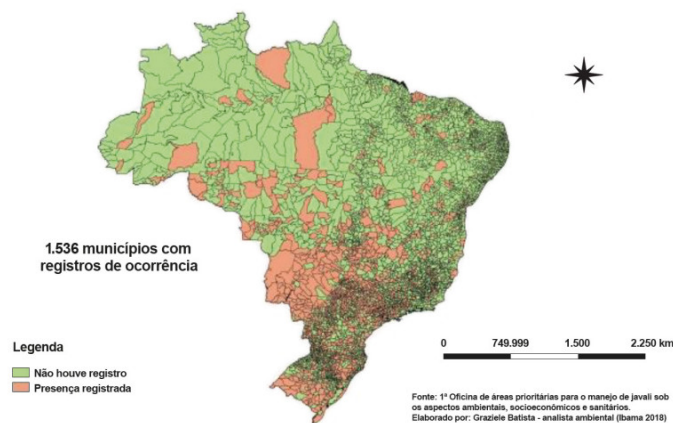


Figure 4. Mapa oficial de ocorrência do javali no Brasil (extrato do Plano Nacional). Fonte: Ibama [Ibama 2020].

## 6. Conclusão (prévia)

A proposta integra detecção robusta, *tracking*, métricas orientadas à segurança e conformidade legal. Próximos passos incluem curadoria de dados brasileiros, teste noturno e avaliação em cenários reais de lavoura.

## References

- Agarwal, S., Krueger, G., Clark, J., Radford, A., Kim, J. W., and Brundage, M. (2021). Evaluating clip: towards characterization of broader capabilities and downstream implications. *arXiv preprint arXiv:2108.02818*.
- BC, L. (2018). North american camera trap images (nacti). <https://lila.science/datasets/nacti/>.

- BC, L. (2021). Swg camera traps 2018–2020. <https://lila.science/datasets/swg-camera-traps/>.
- BC, L. (2024). Lila camera trap datasets (wcs camera traps, etc.). <https://lila.science/datasets/>.
- Brasil (1998). Lei nº 9.605, de 12 de fevereiro de 1998. Diário Oficial da União. Dispõe sobre as sanções penais e administrativas derivadas de condutas e atividades lesivas ao meio ambiente, e dá outras providências. Brasília, DF, 13 fev. 1998. Disponível em: [https://www.planalto.gov.br/ccivil\\_03/leis/19605.htm](https://www.planalto.gov.br/ccivil_03/leis/19605.htm). Acesso em: 4 nov. 2025.
- Campbell, C. J., Barve, V., Belitz, M. W., Doby, J. R., White, E., Seltzer, C., Di Cecco, G., Hurlbert, A. H., and Guralnick, R. (2023). Identifying the identifiers: How inaturalist facilitates collaborative, research-relevant data generation and why it matters for biodiversity science. *BioScience*, 73(7):533–541.
- Chen, L. et al. (2024). Yolo-sag: An improved wildlife object detection algorithm. *Ecological Informatics*. Online first.
- Commons, W. (2025). Wildschwein, nahe pulverstampftor (cropped) — imagem de javali. [https://pt.wikipedia.org/wiki/Javali#/media/Ficheiro:Wildschwein,\\_N%C3%A4he\\_Pulverstampftor\\_\(cropped\).jpg](https://pt.wikipedia.org/wiki/Javali#/media/Ficheiro:Wildschwein,_N%C3%A4he_Pulverstampftor_(cropped).jpg). Acesso em 21 set. 2025. Licença conforme página do arquivo no Wikimedia.
- da Rosa, C. A., Fernandes-Ferreira, H., and Alves, R. R. N. (2018). O manejo do javali (*sus scrofa linnaeus* 1758) no brasil: implicações científicas, legais e éticas das técnicas letais de controle de uma espécie exótica invasora. *Biodiversidade Brasileira*, 8(2):267–284.
- Datasets, H. F. (2024). society-ethics/lila\_camera\_traps. [https://huggingface.co/datasets/society-ethics/lila\\_camera\\_traps](https://huggingface.co/datasets/society-ethics/lila_camera_traps).
- de Sousa Pimenta, I. (2025). Detecção e reconhecimento de espécies de fauna silvestre e doméstica por monitorização de câmaras de disparo automático.
- do Meio Ambiente e dos Recursos Naturais Renováveis, I. B. (2013). Instrução normativa nº 3, de 31 de janeiro de 2013. Diário Oficial da União. Declara a nocividade da espécie exótica invasora javali-europeu (*Sus scrofa*) e autoriza o controle populacional em todo o território nacional. Brasília: IBAMA, 2013. Disponível em: <https://www.ibama.gov.br/>. Acesso em: 4 nov. 2025.
- Everingham, M., Van Gool, L., Williams, C. K., Winn, J., and Zisserman, A. (2010). The pascal visual object classes (voc) challenge. *International journal of computer vision*, 88(2):303–338.
- Fabian, Z., Miao, Z., Li, C., Zhang, Y., Liu, Z., Hernández, A., Montes-Rojas, A., Escucha, R., Siabatto, L., Link, A., et al. (2023). Multimodal foundation models for zero-shot animal species recognition in camera trap images. *arXiv preprint arXiv:2311.01064*.
- Ibama (2013). Instrução normativa ibama nº 03/2013. <https://repositorio.icmbio.gov.br/bitstreams/1deba98f-a90b-4bb0-9097-1813ee21126b/download>.



Ibama (2019). In ibama nº 12/2019 (simaf) — atualização da in 03/2013. <https://www.gov.br/ibama/pt-br/assuntos/biodiversidade/especies-exoticas-invasoras/manejo-e-controle-do-javali>.

Ibama (2020). Plano nacional de prevenção, controle e monitoramento do javali (sumário executivo). [https://www.gov.br/ibama/pt-br/assuntos/notas/2020/manejo-e-controle-de-javalis/20201201Sumario\\_executivoPlanoJavaliSusscrofa.pdf](https://www.gov.br/ibama/pt-br/assuntos/notas/2020/manejo-e-controle-de-javalis/20201201Sumario_executivoPlanoJavaliSusscrofa.pdf). Contém mapa oficial de ocorrência do javali no Brasil. Acesso em 21 set. 2025.

Ibama (2022). Manejo e controle do javali. <https://www.gov.br/ibama/pt-br/assuntos/biodiversidade/especies-exoticas-invasoras/manejo-e-controle-do-javali>.

iNaturalist (2024a). How do licenses work on inaturalist? <https://help.inaturalist.org/en/support/solutions/articles/151000173511-how-do-licenses-work-on-inaturalist-should-i-change-my-1>

iNaturalist (2024b). inaturalist licensed observation images (open data on aws). <https://registry.opendata.aws/inaturalist-open-data/>.

Jobin, A., Ienca, M., and Vayena, E. (2019). The global landscape of ai ethics guidelines. *Nature machine intelligence*, 1(9):389–399.

Kmetiuk, L. B. et al. (2023). Impact of wild boars as exotic species in brazil: A review. *Animals*, 13(12).

LeCun, Y., Bengio, Y., and Hinton, G. (2015). Deep learning. *nature*, 521(7553):436–444.

MINAS, F. . I. . S. (2025). Invasão de javalis representa ameaça para o agro. Acesso em: 04 nov. 2025.

Nandutu, I., Atemkeng, M., and Okouma, P. (2023). Integrating ai ethics in wildlife conservation ai systems in south africa: A review, challenges, and future research agenda. *AI & SOCIETY*, 38(1):245–257.

Pedrosa, F. et al. (2015). Current distribution of invasive feral pigs in brazil: economic impacts and ecological uncertainty. *Perspectives in Ecology and Conservation*.

Puglia, R. G. R. (2023). A aplicação de inteligência artificial no monitoramento comportamental de tamanduá-mirim (*tamandua tetradactyla*) e onça-pintada (*panthera onca*) ex situ.

Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 779–788.

Schütz, A. K. et al. (2024). Automated detection and counting of wild boar in camera trap images. *Animals*, 14(10).

Universe, R. (2024a). Detectageofboar (yolov8) dataset. <https://universe.roboflow.com/yolo-v8-tutorial/detectageofboar>.

Universe, R. (2024b). Wild boar object detection collections. <https://universe.roboflow.com/project-s5fh6/wild-boar-nlhjs>.